Détection automatique de misogynie en ligne: Reddit et les communautés *Incels*

Camille$_1$ **Demers**$_1$* — **Forest**$_2$ **Dominic**$_2$*

* *École de Bibliothéconomie et des Sciences de l'Information, Université de Montréal*

RÉSUMÉ. *Cet article s'intéresse à la détection du discours des communautés Incels (involuntary celibates) sur Reddit. Ces communautés virtuelles regroupent typiquement des hommes partageant une incapacité à lier des relations amoureuses ou sexuelles avec des femmes et alimentant par conséquent une subculture aux tendances misogynes et antiféministes. Compte tenu de la gravité des attaques commises par des individus Incels au cours des dernières années et de leur propension à se radicaliser sous l'effet de chambres d'écho, il s'avère plus que nécessaire de pouvoir détecter ce type de discours. Cette étude compare la performance de classifieurs basés sur les méthodes des K plus proches voisins (kNN) et de la classification bayésienne naïve pour détecter le discours Incel présent dans un corpus de commentaires provenant de Reddit.*

MOTS-CLÉS : *Détection de propos misogynes*$_1$, *Incels*$_2$, *Reddit*$_3$,

TITLE. *Online Misogyny Detection: Reddit and Incels communities*

ABSTRACT. *This article addresses the detection of Incels (involuntary celibates) communities on Reddit. These virtual communities typically bring together men who share an inability to form romantic or sexual relationships with women, and consequently feed a subculture with misogynist and antifeminist tendencies. Given the severity of the attacks committed by certain Incel individuals in recent years as well as their propensity to radicalize under the influence of echo chambers, it is more than necessary to detect the discourse of these communities online. This study compares the detection performance of classifiers based on K-nearest neighbors (kNN) and naive Bayesian classification to identify Incel speech in a corpus of comments collected from Reddit.*

KEYWORDS: *Online misogyny detection*$_1$, *Incels*$_2$, *Reddit*$_3$.

1re soumission à *TAL 65-03*, le 31/05/2024

1. Introduction

> Incel, /insel/
> Nom masculin : « Membre d'une communauté virtuelle composée principalement de jeunes hommes ne se sentant pas attirants envers les femmes, se trouvant dans l'incapacité de trouver une partenaire amoureuse et/ou sexuelle et partageant régulièrement des opinions négatives à propos des femmes, qu'ils blâment comme responsables de leur situation. »
>
> Oxford Advanced Learner's Dictionaries, 2024

Le 7 novembre 2017, à la suite de l'adoption d'une politique interdisant toute forme de contenu prônant ou incitant à la violence, Reddit bannit le forum r/Incels, regroupant alors plus de 40 000 membres (Hauser, 2017). Un an plus tard, le forum en ligne Incels.me est suspendu du registre du domaine .me pour des raisons similaires (.ME, 2018). Malgré la fermeture de ces espaces, les Incels, ou « célibataires involontaires », désignent encore aujourd'hui un ensemble de communautés virtuelles regroupant majoritairement des hommes partageant une incapacité à lier des relations avec les femmes et alimentant par conséquent une subculture aux tendances misogynes et antiféministes (Halpin, 2022 ; Meier et Sharp, 2024).

Bien que leurs activités se voient fréquemment censurées, ces communautés ont été associées à un nombre inquiétant de crimes haineux de même qu'à la glorification d'actes de violence extrême au cours des dernières années. Pour n'en citer que quelques-uns, mentionnons par exemple les événements perpétrés lors de la tuerie d'Isla Vista, où Elliott Rodger a abattu six personnes après avoir annoncé son plan de représailles envers les femmes à travers une vidéo publiée sur YouTube : *"You forced me to suffer all my life, and now I'll make you all suffer"* (Associated Press, 2014 ; ABC News, 2014) ; l'attaque au camion-bélier ayant eu lieu à Toronto en 2018, où Alek Minassian a happé dix personnes à bord d'un véhicule loué pour l'occasion, qu'il a pris la peine de souligner sur sa page Facebook quelques minutes avant de passer à l'acte en saluant au passage son précédesseur : *"The Incel Rebellion has already begun! We will overthrow all the Chads and Stacys! All hail the Supreme Gentleman Elliot Rodger!"* (Duchaine, 2018 ; Nadeau, 2022) ; mentionnons finalement la récente attaque au couteau perpétrée à l'Université de Waterloo, où Geovanny Villalba-Aleman s'est infiltré dans la salle d'un cours portant sur l'identité de genre et y a poignardé trois personnes, un geste ayant fait l'objet de célébrations au sein de communautés Incels (Halpin et al., 2024).

Considérant la difficulté à modérer ces communautés en raison de l'anonymat de leurs membres et de leur propension à se radicaliser sous l'effet de chambres d'échos, il s'avère crucial de pouvoir détecter le discours des communautés *Incels* sur le Web, et en particulier sur le réseau où elles ont historiquement été reconnues être particulièrement actives : Reddit (Ribeiro et al., 2021). Détecter les propos émis par les *Incels* constitue une première étape permettant de caractériser les contextes au sein desquels ces propos sont propagés en vue d'élaborer des stratégies pour diminuer la radica-

lisation d'idéologies misogynes au sein de ces communautés virtuelles. Par ailleurs, le banniseement des espaces où ces groupes sont actifs s'avère peu eficace dans bon nombre de cas : en 2021, Ribero et al. se sont intéresés à l'évolution d'un ensemble de communautés masculinistes - regroupées sous l'appellation "Manospère" - sur différentes plateformes Web, sur une période de 14 ans ; ceux-ci ont démontré que la fermeture de ces espaces de discussion est rapidement suivie par une réorganisation des communautés vers d'autres endroits, ce qui a par ailleurs été confirmé chez les *Incels* : lorsque *r/Incels* fut supprimé en 2017, seuls quelques jours ont suffi pour que ses utilisateurs migrent vers de nouveaux espaces, dont *r/Braincels* et *Incels.is* (Ribeiro et al., 2021). Compte tenu de ces considérations, cet article vise donc à évaluer différents systèmes de détection automatique permettant d'extraire les particularités spécifiques aux propos des communautés *Incels* sur Reddit en les comparant aux autres formes de discours émises sur cette plateforme.

2. Travaux reliés

Plusieurs travaux ont été réalisés dans le domaine de la détection ainsi que de la catégorisation de différents types de propos sexistes et misogynes en ligne (par ex. Saha et al., 2018 ; Frenda et al., 2019 ; Morales-Castro et al., 2023 ; Padmavathi, 2023), cependant peu se sont specifiquement penchés sur la détection automatique du discours Incels. Ceux ayant abordé plus spécifiquement le discours Incel l'ont plutôt exploré au regard de la migration des utilisateurs entre plateformes (Ribeiro et al., 2021), de la toxicité des propos émis au sein de ces communautés (Pelzer et al., 2021 ; Ribeiro et al., 2021), de la richesse lexicale de ce type de discours (Gothard et al., 2021), de la construction d'une identité misogyne chez les Incels (Yoder et al., 2023) ou encore la nature sexiste, raciste ou homophobe du discours Incels (Jaki et al., 2019).

Tel que mentionné plus haut, Ribeiro et al. (2021) ont mené une étude longitudinale portant sur l'évolution des communautés de la Manosphère. Ceux-ci ont constitué un corpus issu de 51 espaces de discussion de la plateforme Reddit (appelés subreddits) ainsi que de six forums en ligne, totalisant 28.8M de commentaires s'échelonnant sur une période de 14 ans. Leurs travaux ont permis d'étudier les migrations et intersections des utilisateurs à travers ces plateformes au moyen de mesures de similarité sémantique (Jaccard Similarity, Overlap Coefficient). Ceux-ci ont également caractérisé le niveau de toxicité des propos au sein de ces communautés en employant un modèle basé sur un réseau neuronal convolutif (CNN). Similairement, Pelzer et al. (2021) ont développé un modèle de détection automatique du niveau de toxicité de trois des plus importants forums Incels connus en 2021, soit Incels.is, Lookisms.net et Looksmax.org. Leurs travaux ont exploité une approche d'apprentissage par transfert basée sur le modèle de langue BERT et ont permis de démontrer que les propos issus des trois forums Incels présentaient un taux de toxicité significativement supérieur à celui d'un corpus contrôle provenant de Reddit. Finalement, en 2019, Jaki et al. ont développé un système de détection des propos à caractère misogyne, homophobe et/ou raciste parmi les commentaires publiés sur le forum Incels.me. Leurs travaux ont

comparé les performances d'un réseau neuronal convolutif (CNN) et d'un classifieur de type perceptron à détecter les propos misogynes, homophobes et/ou racistes parmis les commentaires issus des forums Incels.

Très peu d'études se sont cependant spécifiquement penchées sur la détection automatique du discours Incels en lui-même : les travaux de Hajarian et Khanbabaloo (2021) sont à notre connaissance les seuls s'y étant intéressés, ce qu'ils ont fait avec une approche d'analyse de sentiment combinée à un système de détection des propos injurieux sur un corpus provenant de Twitter et Facebook, leur permettant de détecter le discours Incels sur ces plateformes avec 78.8

3. Données et méthodologie[1]

3.1. *Corpus d'apprentissage*

3.1.1. *Données Incels*

Puisque la tâche de détection visée en est une de classification supervisée, un corpus d'apprentissage a été constitué par la réutilisation de jeux de données existants, dans le but de représenter deux classes d'intérêt : (1) des données provenant de forums Incels sur Reddit ; (2) des données neutres constituant un corpus de référence reflétant l'utilisation du langage sur cette plateforme.

Les données d'apprentissage totalisent 100 000 commentaires, soit 50 000 commentaires Incels et 50 000 publications neutres. Différents corpus de 50 000 commentaires chacun ont par la suite été constitués en faisant varier le ratio de données Incels en vue d'évaluer l'impact de ces proportions sur la performance de classification. Le tableau 1 présente les caractéristiques des différents corpus d'apprentissage constitués. Cette analyse faisant varier le ratio de données Incels dans les corpus d'apprentissage est appliquée dans le but de pallier le problème de déséquilibre des classes auquel fait face la présente tâche, où la classe à détecter est sous-représentée dans la réalité, rendant plus complexe l'extraction de ses spécificités par un modèle de classification (Ling et Sheng, 2010). Puisque la proportion exacte des propos Incels sur le Web sur Reddit est inconnue, les paramètres choisis visent donc à évaluer l'impact que peuvent avoir différentes proportions de données Incels dans les corpus d'apprentissage sur les performance de détection résultantes.

Les données Incels proviennent d'un corpus colligé par Ribeiro et al. (2021). Ce corpus contient plus de 28.8 M de publications provenant de 51 forums Reddit (subreddits), dont nous en avons retenus 15 identifiés par Ribeiro et al. (2021) comme étant spécifiquement Incels (e.g. r/Braincels, r/ForeverUnwanted, r/askanincel). Une approche de type Bag of Communities a été employée pour étiqueter les commen-

1. L'ensemble des corpus d'apprentissage et d'expérimentation, des paramètres ainsi que des scripts de traitement sont disponibles dans un répertoire GitHub à l'adresse suivante : https ://github.com/CamilleDemers/incels-detection-reddit

Proportion de posts Incels (%)	nb formes	nb occurences	nb max traits disciminants
10	58 886	1 689 614	3 653
20	57 284	1 735 550	3 609
30	55 568	1 771 491	3 595
50	52 515	1 868 528	3 551
70	47 535	1 949 643	3 407
90	41 130	2 015 528	3 220

TABLEAU 1. *Constitution de corpus d'apprentissage contenant différents ratios de données Incels*

taires comme étant "Incels" en fonction du subreddit où ils ont été publiés. Malgré ses limites, cette approche permet de pallier l'absence de données annotées en attribuant une catégorie d'appartenance à une communauté entière (un subreddit) plutôt qu'à chaque commentaire considéré individuellement (Chandrasekharan et al., 2017 ; Pelzer et al., 2021). Les données ont été filtrées pour ne retenir que les commentaires émis depuis 2014, afin de refléter le jargon actuel de ces communautés. Toutefois, le corpus de Ribeiro et al. (2021) possède une couverture temporelle s'arrêtant en 2019, de sorte des données supplémentaires issues de 9 subreddits Incels (ex. r/incelsInAction, r/shortcels) y ont été ajoutées pour couvrir la période 2020-2022. Ces données proviennent des archives du projet PushShift (Baumgartner et al., 2020)[2].

3.1.2. *Données neutres*

Pour limiter l'introduction de biais reflétant les spécificités langagières de Reddit plutôt que du discours d'intérêt (Tranchese et Sugiura, 2021), le corpus de données neutres est également constitué de commentaires provenant de Reddit. Ces données proviennent des archives du projet Pushshift (Baumgartner et al., 2020), dont un sous-ensemble de 100 000 commentaires a été extrait aléatoirement. Celui-ci couvre 38 196 subreddits distincts, non reconnus comme étant fréquentés par les communautés Incels (ex. r/AskReddit, r/electronic_cigarette, r/todayilearned, etc.).

3.2. *Corpus test*

Le corpus dédié à l'évaluation des modèles totalise 10 000 données, provenant des mêmes sources dont est issu le corpus d'apprentissage (excluant les données d'apprentissage), c'est-à-dire le corpus rendu disponible par Ribeiro et al. (2021) ainsi que les archives du projet PushShift (Baumgartner et al., 2020). La distribution des données pour la phase de test a été fixée à 10% de données Incels afin de refléter la

2. Ces archives ont été déplacées à l'adresse suivante : https ://the-eye.eu/redarcs/ depuis l'annonce de changements dans les conditions d'utilisation de l'API de Reddit en octobre 2023.

proportion potentiellement réelle de ce discours dans la réalité. En effet, Hajarian et Khanbabaloo (2021) ont rapporté des proportions de propos Incels de l'ordre de 9,1% sur Facebook et 8,5% sur Twitter. Le corpus test compte donc 10 000 données Incels et 90 000 données neutres.

4. Méthodes

4.1. *Prétraitement*

Les données ont été nettoyées afin de retirer les publicités ou les actions automatiques de robots. L'ensemble des traitements subséquents ont été menés avec la librairie python Scikit-Learn (Pedregosa et al., 2011). L'emploi d'un antidictionnaire a permis d'appliquer un filtrage des mots fonctionnels de l'anglais, enrichi d'un ensemble de formes non pertinentes spécifiques au format Web des données (ex. balises et entités HTML, artefacts générés par l'API de Reddit).

4.2. *Phase d'apprentissage*

Différents modèles de classification ont été paramétrés pour détecter la présence de propos Incels dans les commentaires de Reddit. Six modèles de classification ont été comparés : un premier modèle basé sur un algorithme de classification bayésienne naïve (Naive Bayes), puis cinq modèles basés sur l'algorithme des K plus proches voisins (K Nearest Neighbors [kNN]), pour différentes valeurs du paramètre K, allant de 1 à 5 voisins. Nous avons également fait varier le nombre de traits discriminants retenus par les modèles pour des valeurs allant de 1 500 à 15 000 traits, ceux-ci étant sélectionnés en fonction d'une pondération TF-IDF. Une méthode de validation croisée à 5 blocs a été employée pour assurer l'indépendance des modèles aux données d'apprentissage.

4.3. *Phase de test*

Pour la phase de test, le système illustrant la meilleure performance en phase d'apprentissage a été retenu puis testé sur 10 000 données inédites.

5. Résultats et discussion

Les résultats sont évalués au regard de l'exactitude prédictive des modèles, leur sensibilité et leur pertinence, celles-ci étant respectivement évaluées par des mesures de rappel et de précision. La performance globale est évaluée au moyen de la mesure F, qui tient à la fois compte du rappel et de la précision ; cette mesure reflète d'ailleurs plus adéquatement la performance que l'exactitude prédictive dans un contexte de déséquilibre des classes (Zhao et Chen, 2014).

Les tableaux 1 et 2 illustrent les performances des 5 meilleurs systèmes au regard de l'exactitude et du score F. Tous systèmes confondus, l'algorithme bayésien naïf entraîné sur un corpus contenant 10% de données Incels et retenant 4 000 traits discriminants illustre la plus haute exactitude prédicitive (90,84%), cependant avec une mesure F de 0,57. En contrepartie, le modèle basé sur l'algorithme algorithme bayésien naïf entraîné sur un corpus contenant 40% de données Incels et retenant 15 000 traits discriminants illustre la meilleure mesure F (0,77), pour une exactitude prédictive de 77,69%, laquelle demeure comparable aux résultats obtenus par Hajarian et Khanbabaloo (2021) (78,8%). Ce dernier modèle a donc été retenu pour la phase de test.

% *Incels*	Algorithme	Nb traits	Exactitude	Mesure F
10	Naive Bayes	4000	0,9084	0,57
10	Naive Bayes	5000	0,9083	0,57
10	Naive Bayes	3000	0,9081	0,57
10	Naive Bayes	2000	0,9078	0,57
10	Naive Bayes	15 000	0,9074	0,56

TABLEAU 2. *Métriques d'évaluation des 5 classifeurs les plus performants au regard de l'exactitude*

% *Incels*	Algorithme	Nb traits	Exactitude	Mesure F
40	Naive Bayes	15 000	0,7846	0,77
40	Naive Bayes	10 000	0,7826	0,76
40	Naive Bayes	5 000	0,7796	0,76
30	Naive Bayes	4 000	0,7726	0,75
50	Naive Bayes	5 000	0,7468	0,75

TABLEAU 3. *Métriques d'évaluation des 5 classifeurs les plus performants au regard de la mesure F*

Ces résultas suggèrent qu'une proportion plus élevée de propos Incels dans les données d'apprentissage est associée à une meilleur exactitude prédictive du modèle, tandis qu'un nombre plus élevé de traits discriminants est pour sa part associé à un meilleur score F.

La Figure 1 présente la performance des modèles pour différentes proportions de données Incels contenues dans le corpus d'apprentissage. Le classifieur basé sur l'algorithme bayésien naïf performe mieux pour pratiquement toutes les proportions testées, sauf pour le ratio de 90

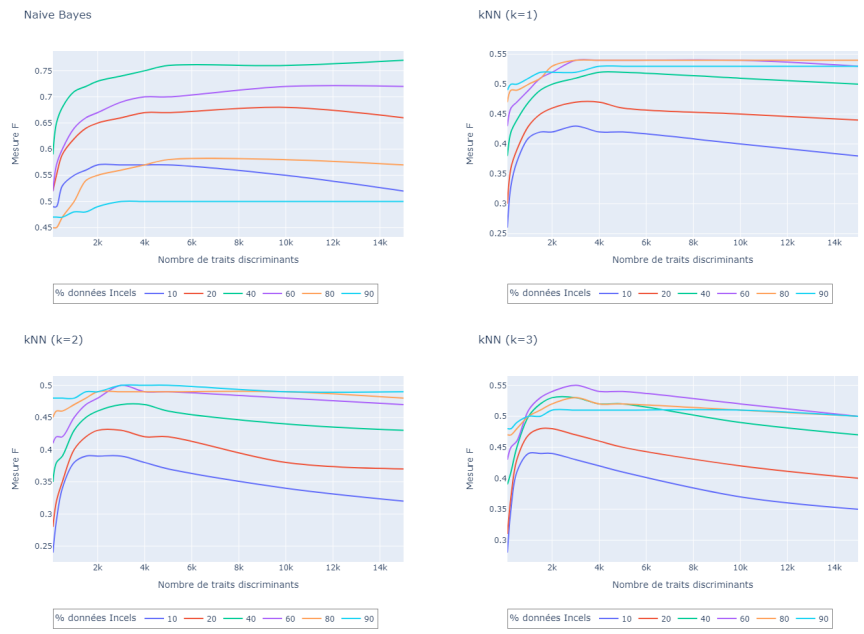

FIGURE 1. *Performances (F-score) des classifieurs en phase d'apprentissage pour différentes proportions de données Incels*

L'ensemble des modèles illustrent des tendances similaires relativement à la variation du nombre de traits disctiminants retenus, caractérisées par une augmentation de performance (mesure F) proportionnelle avec l'emploi d'un plus grand nombre de traits, plafonnant autour de 5000 traits.

Le tableau 3 compare les métriques de performance du modèle retenu en phase de test et en phase d'apprentissage. Celui-ci obtient une meilleure exactitude prédictive qu'en phase d'apprentissage (86,75

	Exactitude	Précision	Rappel	Mesure F
Apprentissage	77,69%	0,78	0,75	0,76
Test	86,75%	0,68	0,76	0,70

TABLEAU 4. *Comparaison des métriques de performance du modèle de classification retenu en phase d'apprentissage et de test (Naive Bayes, 15 000 traits discriminants, 40% de données Incels dans le corpus d'entraînement).*

6. Conclusion

Les travaux présentés dans cette étude ont permis de comparer la performance de différents modèles de classification automatique à détecter le discours des communautés Incels au sein d'un corpus de commentaires provenant de Reddit, en tenant compte du problème de déséquilibre des classes. Le système illustrant la meilleure performance emploie un classifieur bayésien naïf retenant 15 000 traits discriminants. Le classifieur proposé obtient un score F de 0,70, pour une exactitude prédictive de 86,75%. De futurs travaux permettront d'explorer l'évolution des patrons langagiers les plus pertinents pour la détection de ce type de discours à travers le temps.

7. Bibliographie

, *Apprentissage artificiel : Évaluation de l'apprentissage – Précision, Rappel et F-mesure | Blog Onymen*.d.

, *Data Mining Applications with R | ScienceDirect*n.d.

, *Elliot Rodger : Inside the Mind of a Killer*May, 2014.

, *Incel*2021.

, *Reddit/Pushshift Archives*n.d.

Baele S. J., Brace L., Coan T. G., « From "Incel" to "Saint" : Analyzing the violent worldview behind the 2018 Toronto attack », *Terrorism and Political Violence*, vol. 33, nº 8, p. 1-25, August, 2019. Publisher : Routledge _eprint : https ://doi.org/10.1080/09546553.2019.1638256.

Baumgartner J., Zannettou S., Keegan B., Squire M., Blackburn J., « The Pushshift Reddit Dataset », *Proceedings of the International AAAI Conference on Web and Social Media*, vol. 14, p. 830-839, May, 2020.

Beckett L., « The misogynist incel movement is spreading. Should it be classified as a terror threat ? », *The Guardian*, March, 2021.

Bell S., « Despite crackdown on incels, their discussion forums are still online | Globalnews.ca », 2020.

Berrar D., « Cross-Validation », *in* S. Ranganathan, M. Gribskov, K. Nakai, C. Schönbach (eds), *Encyclopedia of Bioinformatics and Computational Biology*, Academic Press, Oxford, p. 542-545, January, 2019.

Chandrasekharan E., Samory M., Srinivasan A., Gilbert E., « The Bag of Communities : Identifying Abusive Behavior Online with Preexisting Internet Data », *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*, CHI '17, Association for Computing Machinery, New York, NY, USA, p. 3175-3187, May, 2017.

Chang W., « The monstrous-feminine in the incel imagination : Investigating the representation of women as "femoids" on /r/Braincels », *Feminist Media Studies*, vol. 22, nº 2, p. 254-270, February, 2022. Publisher : Routledge _eprint : https ://doi.org/10.1080/14680777.2020.1804976.

Duchaine G., « «La rébellion incel a déjà commencé», a écrit l'auteur de l'attaque à Toronto », *La Presse*, April, 2018.

Farrell T., Fernandez M., Novotny J., Alani H., « Exploring Misogyny across the Manosphere in Reddit », *Proceedings of the 10th ACM Conference on Web Science*, WebSci '19, Association for Computing Machinery, New York, NY, USA, p. 87-96, June, 2019.

Fersini E., Nozza D., Rosso P., « AMI @ EVALITA2020 : Automatic Misogyny Identification », *in* V. Basile, D. Croce, M. D. Maro, L. C. Passaro (eds), *Proceedings of the Seventh Evaluation Campaign of Natural Language Processing and Speech Tools for Italian. Final Workshop (EVALITA 2020)*, vol. 2765 of *CEUR Workshop Proceedings*, CEUR, Online event, December, December, 2020. ISSN : 1613-0073.

Forest D., van Hoeydonck A., Létourneau D., Bélanger M., « Impacts de la variation du nombre de traits discriminants sur la catégorisation des documents », Paris, June, 2009.

Frenda S., Ghanem B., Montes-y Gómez M., Rosso P., « Online Hate Speech against Women : Automatic Identification of Misogyny and Sexism on Twitter », *Journal of Intelligent & Fuzzy Systems*, vol. 36, nº 5, p. 4743-4752, January, 2019. Publisher : IOS Press.

Gothard K., Dewhurst D. R., Minot J. R., Adams J. L., Danforth C. M., Dodds P. S., « The incel lexicon : Deciphering the emergent cryptolect of a global misogynistic community », *arXiv :2105.12006 [cs]*, May, 2021. arXiv : 2105.12006.

Hajarian M., Khanbabaloo Z., « Toward Stopping Incel Rebellion : Detecting Incels in Social Media Using Sentiment Analysis », *2021 7th International Conference on Web Research (ICWR)*, p. 169-174, May, 2021.

Halpin M., « Weaponized Subordination : How Incels Discredit Themselves to Degrade Women », *Gender & Society*, vol. 36, nº 6, p. 813-837, December, 2022. Publisher : SAGE Publications Inc.

Halpin M., Preston K., Lockyer D., Maguire F., « A solider and a victim : Masculinity, violence, and incels celebration of December 6th », *Canadian Review of Sociology/Revue canadienne de sociologie*p. cars.12460, January, 2024.

Hauser C., « Reddit Bans 'Incel' Group for Inciting Violence Against Women », *The New York Times*, November, 2017.

Hill K., « The Disturbing Internet Footprint Of Santa Barbara Shooter Elliot Rodger », 2014. Section : Tech.

Hoffman B., Ware J., Shapiro E., « Assessing the Threat of Incel Violence », *Studies in Conflict & Terrorism*, vol. 43, nº 7, p. 565-587, July, 2020. Publisher : Routledge _eprint : https ://doi.org/10.1080/1057610X.2020.1751459.

Jaki S., Smedt T. D., Gwóźdź M., Panchal R., Rossa A., Pauw G. D., « Online hatred of women in the Incels.me forum : Linguistic analysis and automatic detection », *Journal of Language Aggression and Conflict*, vol. 7, nº 2, p. 240-268, November, 2019. Publisher : John Benjamins.

Javaheri S. H., Sepehri M. M., Teimourpour B., « Chapter 6 - Response Modeling in Direct Marketing : A Data Mining-Based Approach for Target Selection », *in* Y. Zhao, Y. Cen (eds), *Data Mining Applications with R*, Academic Press, Boston, p. 153-180, January, 2014.

Ling C. X., Sheng V. S., « Class Imbalance Problem », *in* C. Sammut, G. I. Webb (eds), *Encyclopedia of Machine Learning*, Springer US, Boston, MA, p. 171-171, 2010.

Lynn T., Endo P. T., Rosati P., Silva I., Santos G. L., Ging D., « A Comparison of Machine Learning Approaches for Detecting Misogynistic Speech in Urban Dictionary », *2019 International Conference on Cyber Situational Awareness, Data Analytics And Assessment (Cyber SA)*, p. 1-8, June, 2019.

Manning C. D., Raghavan P., Schütze H., « Introduction to Information Retrieval », July, 2008. ISBN : 9780511809071 Publisher : Cambridge University Press.

Matter D., Schirmer M., Grinberg N., Pfeffer J., « Close to Human-Level Agreement : Tracing Journeys of Violent Speech in Incel Posts with GPT-4-Enhanced Annotations », January, 2024. arXiv :2401.02001 [cs].

.ME, « The suspension of incels.me • Domain .ME blog », November, 2018.

Meier M. L., Sharp K., « Death to Chad and Stacy : Incels and anti-fandom as group identity », *International Journal of Cultural Studies*p. 13678779231220056, January, 2024. Publisher : SAGE Publications Ltd.

Morales-Castro J. C., Hernandez-Rayas A., Ruiz-Pinales J., Guzmán-Cabrera R., « Automatic Identification of Misogynistic Sentiments on Social Networks », *Journal of Social Researches*, vol. 9, nº 23, p. 10-18, 2023.

Nadeau J.-P., « Attaque au camion-bélier : Alek Minassian condamné à 25 ans minimum », *Radio-Canada*, June, 2022. Publisher : Radio-Canada.ca.

Padmavathi M., « DS at SemEval-2023 Task 10 : Explaining Online Sexism using Transformer based Approach », *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, Association for Computational Linguistics, Toronto, Canada, p. 1102-1106, July, 2023.

Pedregosa F., Varoquaux G., Gramfort A., Michel V., Thirion B., Grisel O., Blondel M., Prettenhofer P., Weiss R., Dubourg V., Vanderplas J., Passos A., Cournapeau D., Brucher M., Perrot M., Duchesnay E., « Scikit-learn : Machine Learning in Python », *Journal of Machine Learning Research*, vol. 12, p. 2825-2830, 2011.

Pelzer B., Kaati L., Cohen K., Fernquist J., « Toxic language in online incel communities », *SN Social Sciences*, vol. 1, nº 8, p. 213, August, 2021.

Pineda A., « Alek Minassian aurait été motivé par une haine des femmes », *Le Devoir*, 2018.

Pitsilis G. K., Ramampiaro H., Langseth H., « Effective hate-speech detection in Twitter data using recurrent neural networks », *Applied Intelligence*, vol. 48, nº 12, p. 4730-4742, December, 2018.

Press A., « Le suspect d'une tuerie en Californie est le fils d'un réalisateur de Hollywood », *Radio-Canada*, May, 2014. Publisher : Radio-Canada.ca.

Ribeiro M. H., Blackburn J., Bradlyn B., Cristofaro E. D., Stringhini G., Long S., Greenberg S., Zannettou S., « Dataset for : The Evolution of the Manosphere Across the Web », August, 2020.

Ribeiro M. H., Blackburn J., Bradlyn B., Cristofaro E. D., Stringhini G., Long S., Greenberg S., Zannettou S., « The Evolution of the Manosphere across the Web », *Proceedings of the International AAAI Conference on Web and Social Media*, vol. 15, p. 196-207, May, 2021.

Saha P., Mathew B., Goyal P., Mukherjee A., « Hateminers : Detecting Hate speech against Women », *arXiv :1812.06700 [cs]*, December, 2018. arXiv : 1812.06700.

Schumacher A., « When (not) to Lemmatize or Remove Stop Words in Text Preprocessing », March, 2019.

Shibly F. H. A., Sharma U., Naleer H. M. M., « Automatic Detection of Online Hate Speech Against Women Using Voting Classifier », *in* D. Gupta, A. Khanna, S. Bhattacharyya, A. E. Hassanien, S. Anand, A. Jaiswal (eds), *International Conference on Innovative Computing*

and Communications, Lecture Notes in Networks and Systems, Springer Nature, Singapore, p. 735-745, 2023.

Shushkevich E., Cardiff J., « Automatic Misogyny Detection in Social Media : A Survey », *Computación y Sistemas*, December, 2019.

Tranchese A., Sugiura L., « "I Don't Hate All Women, Just Those Stuck-Up Bitches" : How Incels and Mainstream Pornography Speak the Same Extreme Language of Misogyny », *Violence Against Women*, vol. 27, nº 14, p. 2709-2734, November, 2021. Publisher : SAGE Publications Inc.

Yoder M. M., Perry C., Brown D. W., Carley K. M., Pruden M. L., « Identity Construction in a Misogynist Incels Forum », July, 2023a. arXiv :2306.15745 [cs].

Yoder M., Perry C., Brown D., Carley K., Pruden M., « Identity Construction in a Misogynist Incels Forum », *The 7th Workshop on Online Abuse and Harms (WOAH)*, Association for Computational Linguistics, Toronto, Canada, p. 1-13, 2023b.

Zhao Y., Chen Y., *Data Mining Applications with R*, Elsevier, 2014.

Zhou L., Caines A., Pete I., Hutchings A., « Automated hate speech detection and span extraction in underground hacking and extremist forums », *Natural Language Engineering*p. 1-28, June, 2022. Publisher : Cambridge University Press.